

Introduction à l'Intelligence Artificielle

Bases, concepts, mutations génératives et souveraineté industrielle



MODULE 1

DÉMYSTIFIER L'INTELLIGENCE ARTIFICIELLE


Histoire, concepts fondamentaux, cybernétique et formes d'intelligence


Grandes thématiques & compétences développées dans ce module :

- Représentations & Définitions : Qu'est-ce que l'IA pour vous ? Dépasser les mythes de la science-fiction.
- Formes d'Intelligence : De la théorie des intelligences multiples (Howard Gardner) au test de Turing.
- Origines Historiques : Des conférences Macy (1946-1953) et de Dartmouth (1956) aux premiers hivers de l'IA.
- Les Deux Grands Courants : L'approche symbolique (règles logiques) face à l'approche connexionniste (données).

- **C'est quoi l'IA pour vous ?**
- Tour de table rapide : "Citez une IA que vous connaissez ou utilisez au quotidien." (Ex: GPS, Siri/Gemini, Netflix, ChatGPT, Midjourney...).
- **Discussion** : Qu'est-ce que ces outils ont en commun ? Quelles sont vos premières impressions (enthousiasme, méfiance) ?
- **Et pourquoi faire ?**

Comment appréhender un problème ?





★ Une brève histoire de l'IA



Années 1830 : Le Rêve Mécanique
Charles Babbage conçoit la Machine Analytique. Ada Lovelace écrit le premier algorithme.

Systèmes symboliques
(1950 -> 1980)

Symboles
Règles explicites

Systèmes statistiques
et apprentissage
automatique
(1980 -> 2010)

Données

Apprentissage profond
(2010 -> auj.)

Perception
Interaction

Un Voyage dans le Temps

Découvrez les moments clés qui ont façonné l'Intelligence Artificielle.



La Genèse (1940-1956)

Le Rêve des Machines Pensantes

Alan Turing (1950) : Pose la question fondatrice "Les machines peuvent-elles penser ?" et propose le célèbre Test de Turing.

McCulloch & Pitts (1943) : Créent le premier modèle mathématique de neurone artificiel, fondant l'idée que la pensée peut être modélisée comme un calcul logique.

Dartmouth Workshop (1956) : Naissance officielle du terme "Intelligence Artificielle" avec l'ambition de simuler l'intelligence humaine.



Frank Rosenblatt

1

2

FIG. 1 — Organization of a biological brain. (Red areas indicate active cells, responding to the letter X.)




FIG. 2 — Organization of a perceptron.

L'Âge d'Or et le 1er Hiver (1956-1980)

L'Enthousiasme et la Douche Froide

Les premières IA comme **ELIZA** (1966) et le **Perceptron** (1957) suscitent un immense espoir. On distingue l'approche **connexionniste** (apprendre par l'exemple) et **symbolique** (programmer des règles).

Le **"Premier Hiver de l'IA"** arrive : les promesses sont trop grandes, la puissance de calcul trop faible, les limites techniques (ex: incapacité du Perceptron à résoudre des problèmes simples comme le XOR) et des rapports critiques (Rapport Lighthill, 1973) coupent les financements.

L'Ère du Deep Learning (1993-Aujourd'hui)

La Révolution des Données et du Calcul

La convergence de 3 facteurs déclenche la révolution :

1. **Algorithmes performants** : En 2012, **AlexNet** (un CNN) gagne la compétition ImageNet. Le **Deep Learning** devient la norme.
2. **Big Data** : Internet fournit une quantité massive de données pour l'entraînement.
3. **Puissance de calcul** : Les **GPU** des jeux vidéo sont détournés pour accélérer les calculs de l'IA.

3

Le Printemps et le 2ème Hiver (1980-1993)

Le Retour des Experts

L'IA symbolique connaît son heure de gloire avec les **Systèmes Experts** (ex: MYCIN), efficaces dans des domaines très spécialisés.

En parallèle, l'approche connexionniste fait un bond en avant avec la popularisation de la **rétropropagation du gradient** (1986), la clé manquante pour entraîner des réseaux de neurones profonds.

Le **"Deuxième Hiver de l'IA"** survient car les systèmes experts sont trop rigides et coûteux à maintenir.

4

[intelligence]



D'autres formes d'intelligence



Science

Social signal learning of the waggle dance in honey bees

Science, 9 mars 2023

<https://www.science.org/doi/10.1126/science.ade1702>

Apprentissage du signal social de la danse frétilleante chez les abeilles domestiques.

Cultural flies: Conformist social learning in fruitflies predicts long-lasting mate-choice traditions

Science, 30 novembre 2018

<https://doi.org/10.1126/science.aat1590>


« Le conformisme de l'apprentissage social chez les mouches prédit des traditions durables en matière de choix de partenaire »

[intelligence]

« Capacité de percevoir ou d'inférer l'information, et de la conserver comme une connaissance à appliquer à des comportements adaptatifs dans un environnement ou un contexte donné »

« Ability to perceive or infer information, and to retain it as knowledge to be applied towards adaptive behaviors within an environment or context »*





[intelligence]

« Ensemble des **fonctions** mentales ayant pour objet la connaissance **conceptuelle** et **rationnelle** »*

« Set of mental functions aimed at conceptual, rational knowledge »

D'un point de vue plus scientifique, **Howard Gardner** (*Gardner, H. [Intelligences multiples -1993](#)*) à travers sa théorie des intelligences multiples, discute aujourd'hui de 8 types d'intelligence :

- L'intelligence linguistique (ou capacité à s'exprimer)
- l'intelligence logico-mathématique (ou capacité à penser de manière abstraite et à raisonner)
- l'intelligence intrapersonnelle (ou capacité à se connaître soi-même)
- l'intelligence interpersonnelle (ou capacité à interagir les uns avec les autres)
- l'intelligence kinesthésique (ou capacité à utiliser son corps)
- l'intelligence musicale (ou capacité à créer, reproduire, reconnaître des sons, des rythmes, des mélodies)
- l'intelligence visuelle et spatiale (ou capacité à se repérer dans l'espace)
- l'intelligence naturelle (ou capacité à comprendre et à interagir avec la nature)

<https://synapses-lamap.org/2020/04/02/que-peut-on-dire-de-lidee-dintelligences-multiples-et-de-sa-application-en-classe/>

L'intelligence artificielle, de quelle forme d'intelligence s'agit-il ?

l'intelligence artificielle est « **l'ensemble des théories et des techniques mises en œuvre pour créer des machines capables de simuler l'intelligence humaine** »

les grands principes de la logique et du raisonnement, que sont les principes de déduction, d'induction ou d'inférence que nous utilisons dans notre raisonnement quotidien pour prendre des décisions, sont également les grands principes des familles de méthodes de l'IA.

Intelligence Artificielle

IA Symbolique

L'IA de la logique et des règles.

- Raisonnement
- Connaissance explicite
- Systèmes experts

Utilise des symboles et des règles de traitement de l'information pour effectuer des tâches, à la manière d'un expert humain qui suit une procédure.

IA Connexionniste

Données

Niveau 2

Machine Learning

Apprentissage

Niveau 3

Deep Learning

Profondeur / Réseaux

Niveau 4

Architectures Clés Transformers

Attention

Niveau 5

IA Générative

Création

Niveau 6

LLM (Grands Modèles de Langage)

Langage

Niveau 7

GPT

Famille de modèles

Niveau 8

ChatGPT

Application

principales méthodes de machine learning

supervisé

classification

données avec label
(pixels) -> (nombre)




regrouper automatiquement les objets en classes, et prédire l'appartenance d'un nouvel objet à une classe identifiée

type d'objet : complexes (image, voix, ...)

exemples : prédire si une tumeur est cancéreuse en fonction de critères multiples, identifier un spam

régression

données avec label
prévoir (y) en fonction de (x)



prédire une valeur en fonction de données d'entraînement multidimensionnelles


type d'objet : valeurs numériques continues

exemples : anticipation de churn client, de demande client, évaluation de pipe client, prévision de panne, prévision de récurrence

non supervisé

clustering

données sans label
(x, y, z, ...)




segmenter automatiquement un jeu de vecteurs (x, y, z, etc)

type d'objet : ensemble de n-uplets de valeurs numériques

exemples : détection de fraude, blanchiment d'argent sale, détection de faille de sécurité

réduction dimensions

données sans label
(x, y, z, ...)




déterminer automatiquement les paramètres discriminants d'un jeu de données par rapport à une variable cible

type d'objet : ensemble de n-uplets de valeurs numériques

exemples : identifier les paramètres déterminants la corrélation entre des paramètres clients et leur comportement futur


Mais ce n'est pas que ça !


[*-learning]



Supervised learning

Learning from labeled data





Classification :

Predict qualitative informations



This is a cat



This is a rabbit




Tell me,
what is it ?



Supervised learning

Learning from labeled data



Classification :

Predict qualitative informations



This is a cat



This is a rabbit



Tell me,
what is it ?



Régression :

Predict quantitative informations



150 K€



400 K€




120 K€



100 K€




Tell me,
what's the
price ?




Linear regression

We have a phenomenon, for which we have observations



Linear regression

"As close as possible" means "minimize the distance" between the line and our points (observations).



Linear regression


$$\hat{\theta} = (X^T X)^{-1} X^T Y$$



Good news !
We have a direct solution !




Bad news...
Complexity in n^3



Loss function









We will use an «loss function», which we will try to minimize.



RMSE : Root Mean Square Error - Erreur quadratique moyenne

MSE : Mean Squared Error - Moyenne du carré des erreurs

Optimization



We will iteratively look for the best position of our line, by varying its parameters (Θ).


This is called **optimization**

Optimization



We will iteratively look for the best position of our line, by varying its parameters (Θ).

This is called **optimization**



Gradient descent



By changing Θ from $\delta\Theta$
We improve $\text{loss}(\Theta)$ of δloss


The gradient is the slope we will
follow to minimize our loss function.

$$\text{gradient} = \frac{\delta\text{loss}}{\delta\theta}$$

One iterative solution is : $\theta \leftarrow \theta - \eta \cdot \frac{\delta\text{loss}}{\delta\theta}$


where η is the learning rate

This process is called
gradient descent






Tout n'est pas linéaire

Polynomial regression




$$P_n(x) = a_0 + a_1 \cdot x + a_2 \cdot x^2 + \dots + a_n \cdot x^n = \sum_{i=0}^n a_i \cdot x^i$$

Underfitting and overfitting



Unsupervised learning

Learning from data **alone**




Unsupervised learning


Clustering : Finding Common Relationships



What is the relationship between these data ?



Learning from data alone




Modéliser le cerveau :

« Penser s'apparente à un calcul massivement parallèle de **fonctions élémentaires**.

L'information est un **signal** avant d'être un code »¹

Connexionniste

Modéliser le cerveau
Modelling the brain



¹ D Cardon, JP Cointet, A Mazieres (2018), La revanche des neurones
<https://dx.doi.org/10.3917/res.211.0173>

Forger une opinion :



« Penser, c'est calculer des **symboles** qui ont à la fois une réalité matérielle et une valeur sémantique de représentation »¹

L'information est une donnée symbolique de **haut niveau**.

Symbolique

Forger une opinion
Making a mind

Tout [homme] est [mortel]
[Socrate] est un [homme]
Donc [Socrate] est [mortel]



The big
Controversy

Approche **inductive**



Connexionniste

Modéliser le cerveau
Modelling the brain

vs

Approche **déductive**




Symbolique

Forger une opinion
Making a mind


Influence académique des approches connexionniste et symbolique¹

Ratio des publications **connexionnistes** / **symbolistes**




¹ D Cardon, JP Cointet, A Mazieres (2018), La revanche des neurones
<https://dx.doi.org/10.3917/res.211.0173>

Influence académique des approches connexionniste et symbolique¹




¹ D Cardon, JP Cointet, A Mazieres (2018), La revanche des neurones
<https://dx.doi.org/10.3917/res.211.0173>

Perceptron



Linear and binary classifier





Perceptron
Frank Rosenblatt
1958



Rosenblatt, F. (1958). The perceptron: A probabilistic model for information storage and organization in the brain.
<https://doi.org/10.1037/h0042519>


Okay, let's look at an example ! **Logistic regression**

Let's try to predict our students' success in an exam, based on their work time and sleep time:







Logistic regression

$$\hat{y} = \sigma(\Theta^T \cdot X + b)$$



Logistic regression



MODULE 2

SOUS LE CAPOT DE L'INTELLIGENCE ARTIFICIELLE

Du Machine Learning aux Réseaux de Neurones et au Deep Learning

Grandes thématiques & compétences développées dans ce module :

- Paradigmes du Machine Learning : Apprentissage supervisé vs non-supervisé à travers l'exemple classique du dataset Iris.
- Le Neurone Artificiel & le Perceptron : Poids synaptiques, biais, fonctions d'activation et descente de gradient.
- La Révolution du Deep Learning (2012) : Rôle historique d'AlexNet sur ImageNet, parallélisation GPU et fin des hivers.
- Grands Domaines d'Application : Vision par ordinateur, traitement du signal acoustique et modèles séquentiels.

Perceptron


```
data(iris)
```

```
data <- iris[iris$Species %in% c("setosa", "versicolor"), ]
```

```
Y <- ifelse(data$Species == "setosa", 1, 0)
```


Iris plants dataset

Dataset from : Fisher, R.A. "The use of multiple measurements in taxonomic problems" Annual Eugenics, 7, Part II, 179-188 (1936)




Length	Width	Iris Setosa (0/1)
x_1	x_2	y
1.4	1.4	1
1.6	1.6	1
1.4	1.4	1
1.5	1.5	1
1.4	1.4	1
4.7	4.7	0
4.5	4.5	0
4.9	4.9	0
4.0	4.0	0
4.6	4.6	0
(...)		

Influence académique des approches connexionniste et symbolique¹




¹ D Cardon, JP Cointet, A Mazieres (2018), La revanche des neurones
<https://dx.doi.org/10.3917/res.211.0173>

Influence académique des approches connexionniste et symbolique¹




¹ D Cardon, JP Cointet, A Mazieres (2018), La revanche des neurones

Deep Neural Networks





Deep Neural Networks




Combien de neurones pour être intelligent ?

Un neurone, c'est **bien**... mais plusieurs, **c'est mieux** ! 






Performances du Top 500¹



Evolution des Datasets²




TOP500:

Pôle Formation GIMM - CVD | Formateur : S. JAUBERT | Module 2 : Sous le capot de l'IA | 50/81

<https://www.top5performance00.org/>

https://en.wikipedia.org/wiki/List_of_datasets_for_machine-learning_research

Performance Development¹




25
ans

$\times 10^6$
Flops

$\times 10^6$
datasets

Datasets for machine-learning²



Laboratoire
Cas particulier




Monde réel


Le tournant en 2012

The big Controversy

Publications SVM vs DNN¹



Classification d'images Top 5 error at ILSVRC 2012^{3,4}



Bien que sans garantie mathématique, les DNN se sont révélés bien plus efficaces face à la **complexité du monde réel** !

¹ Web of Science

² AlexNet at ILSVRC, <https://image-net.org/challenges/LSVRC/2012/results.html>

³ ImageNet Large Scale Visual Recognition, <https://www.image-net.org/challenges/LSVRC/>


⁴ Similar evolution in NLP, translation, board games, etc.
See : DeepL.com, AlphaGo, AlphaZero, ...

Histoire du Deep Learning


D'AlexNet vers l'AGI...



D'AlexNet vers l'AGI...



? L'hypercroissance
à l'époque de la
« sobriété »... ?






14 Jours
1 NVIDIA M40 GPU

14 Jours GPU

Classification (1000 classes)

25 M paramètres (Resnet-50)

1,2 M labeled images






Génération de texte (LLM)

176 B paramètres
366 B tokens (~3 M livres)

117 Jours
384 A100 GPU

44 928 Jours GPU

123 ans






Génération de texte (LLM)

405 B paramètres
15 T tokens (~150 M livres)

54 Jours
16 384 H100 GPU

884 736 Jours GPU

2400 ans



Quand l'IA ...est devenue Hype !!



Des progrès fulgurants !





DES PROGRÈS
FULGURANTS


TILT




Quand l'IA ...est devenue Hype !!



Quand l'IA ...est devenue Hype !!



Vers l'AGI ?



Des datasets de plus en plus gros, atteignant les limites de l'univers numérique !!

L'enjeu des données...

Les données sont essentielles...

Elles peuvent être :



Fermée



Ouvertes



Trop souvent
infernales !!


Représentativité ?
Qualité ?
Quantité ?
Complexité ?
Descripteur ?
Incomplètes ?
...

Apropriation... ?



Une appropriation sociale sans précédent.

Temps nécessaire pour d'atteindre 1 million d'utilisateurs :



<https://www.statista.com/chart/29174/time-to-one-million-users/>



Par exemples :



Biais ?

Explicabilité ?

Impacts sociétaux et environnementaux ?

Syndrome MAD* ?

Transposition dans le monde réel ?

Capacité à suivre ?

Etc.

>9,000 publications par mois...



MODULE 3

MUTATIONS GÉNÉRATIVES & SYSTÈMES AGENTIQUES (2022-2026)

L'ère des Transformers, du raisonnement délibératif et des agents industriels

Grandes thématiques & compétences développées dans ce module :

- Architecture Transformer & Auto-Attention (Vaswani 2017) : Rupture majeure avec le traitement séquentiel RNN/LSTM.
- IA Multimodale en Atelier : Fusion sémantique conjointe de la vision haute cadence, de l'acoustique et des capteurs.
- Modèles de Raisonnement (System 1 vs System 2) : Chaîne de pensée (CoT), délibération pas-à-pas et auto-correction.
- Architecture RAG Industrielle : Ancrage documentaire sécurisé des LLM sur les manuels, plans et gammes de l'usine.
- Systèmes Agentiques & Protocole MCP : Standard ouvert Anthropic pour interconnecter l'IA aux ERP, GMAO et automates.


Révolution Générative & Mécanisme d'Attention des Transformers

De la classification discriminante à la génération contextuelle

- Rupture avec les RNN/LSTM : Abandon du traitement séquentiel au profit d'une parallélisation massive sur GPU grâce à l'auto-attention.
- Formulation mathématique fondamentale : $\text{Attention}(Q, K, V) = \frac{\text{softmax}(Q \cdot K^T / \sqrt{d_k})}{\sum} \cdot V$ calculant le poids contextuel de chaque token.
- Changement de paradigme : Les modèles ne classent plus de simples données, ils prédisent le prochain token dans un espace latent ultra-dimensionnel.
- Impacts atelier : Compréhension instantanée de documentations techniques, génération de code automate et synthèse de retours d'expérience.

Sources & Références Officielles :

- › Vaswani et al. (2017) : Attention Is All You Need (arXiv:1706.03762) — <https://arxiv.org/abs/1706.03762>
- › Stanford HAI : Artificial Intelligence Index Report 2024 — <https://aiindex.stanford.edu/report/>



Architecture Encodeur-Décodeur Transformer (Vaswani et al., NeurIPS 2017)


L'IA Multimodale en Atelier : Vision, Son, Capteurs & Télémétrie

Fusion de données hétérogènes dans un même espace d'encodage

- Espace latent partagé : Alignement mathématique des représentations visuelles (pixels), sonores (spectrogrammes) et textuelles (rapports).
- Contrôle qualité haute cadence : Segmentation temps réel de défauts de surface sur pièces usinées avec localisation millimétrique.
- Maintenance prédictive acoustique : Corrélation instantanée entre vibrations anormales d'un roulement et historique de maintenance GMAO.
- Assistance opérateur terrain : Prise de photo d'un code défaut sur automate avec diagnostic instantané et procédure de consignation validée.

Sources & Références Officielles :

- › Meta AI Research : Segment Anything Model (arXiv:2304.02643) — <https://arxiv.org/abs/2304.02643>
- › Journal of Manufacturing Systems : Multimodal Industrial Inspection (2024) — <https://doi.org/10.1016/j.jmsy.2024.01.008>



Pipeline d'ingestion multimodale et diagnostic atelier unifié


Modèles de Raisonnement & Chaîne de Pensée (System 1 vs System 2)

Passage de la réponse réflexe au calcul logique pas-à-pas

- Limites du Système 1 (LLM standards) : Réponse statistique token par token sans retour en arrière, risque élevé d'hallucinations sur calculs complexes.
- Paradigme Système 2 (o1, DeepSeek-R1) : Génération préalable de tokens de délibération cachés (Chain-of-Thought) avant d'émettre la conclusion.
- Exploration et retour arrière (backtracking) : L'IA formule des hypothèses, teste leur cohérence logique, backtracke si nécessaire et s'auto-corrige.
- Applications industrielles : Ordonnancement complexe de production sous contraintes multiples, calcul de tolérancement et diagnostics sécurité.

Sources & Références Officielles :

- › Wei et al. (Google Brain) : Chain-of-Thought Prompting (arXiv:2201.11903) — <https://arxiv.org/abs/2201.11903>
- › DeepSeek-AI (2025) : DeepSeek-R1: Incentivizing Reasoning in LLMs — <https://arxiv.org/abs/2501.12948>



Comparaison cognitive : Génération token réflexe vs Délibération pas-à-pas avec CoT


Architecture RAG Industrielle (Retrieval-Augmented Generation)

Ancrage des modèles sur la documentation privée de l'usine

- Le problème fondamental : Un modèle pré-entraîné ignore vos plans internes, vos gammes d'usinage et vos procédures confidentielles.
- Principe du RAG : Découpage des documents techniques en fragments (chunks), indexation vectorielle (embeddings) et recherche de similarité cosinus.
- Injection contextuelle : Les extraits exacts des manuels machines sont injectés dans le prompt en temps réel pour guider la réponse du LLM.
- Traçabilité & Auditabilité : Chaque recommandation générée mentionne explicitement le numéro de page et le document technique source vérifié.

Sources & Références Officielles :

- › Lewis et al. / Meta AI : Retrieval-Augmented Generation (arXiv:2005.11401) — <https://arxiv.org/abs/2005.11401>
- › Microsoft Architecture Center : Enterprise RAG Design Patterns (2024) — <https://techcommunity.microsoft.com/>



Architecture de génération augmentée par récupération vectorielle d'atelier

Systèmes Agentiques & Protocole Ouvert MCP (Model Context Protocol)

De l'assistant conversationnel à l'agent d'action interconnecté


- Du Chatbot à l'Agent : Capacité autonome à percevoir l'environnement, planifier des sous-tâches, appeler des outils (Tool Calling) et vérifier le résultat.
- Le standard MCP (Anthropic fin 2024) : Protocole ouvert évitant le développement de connecteurs propriétaires ad-hoc pour chaque outil d'usine.
- Passerelles d'atelier : Serveurs MCP interfaçant directement l'ERP (SAP), la GMAO, les bases SQL et les automates industriels via OPC-UA.
- Gouvernance & Sécurité : Cloisonnement strict des accès, audit des traces d'exécution et nécessité impérative du contrôle humain (Human-in-the-Loop).

Sources & Références Officielles :

- › Anthropic : Model Context Protocol Specification (2024) — <https://modelcontextprotocol.io/>
- › Linux Foundation : Open Standards for Agentic AI Systems (2025) — <https://www.linuxfoundation.org/>

LE PROTOCOLE OUVERT MCP (Model Context Protocol - Anthropic 2024)

Standard ouvert d'interconnexion universelle entre LLM et outils d'entreprise



Standard ouvert MCP : Interconnexion unifiée entre LLM et systèmes industriels (Anthropic, 2024)

MODULE 4

SOUVERAINETÉ, AI ACT & POSTURE DE L'INGÉNIEUR (2024-2026)

Régulation européenne, frugalité industrielle et esprit critique face à la machine

Grandes thématiques & compétences développées dans ce module :

- Règlement Européen AI Act (UE 2024/1689) : Pyramide des 4 niveaux de risques et exigences des machines à haut risque.
- Souveraineté Numérique & Modèles Ouverts : Les atouts d'Open-Weights (Mistral, Llama) déployés On-Premise Air-Gapped.
- Déploiement Local & Frugalité : Petits modèles de langage (SLM) et quantification 4-bit/8-bit (AWQ, GGUF) sur matériel atelier.
- Bilan Énergétique & Empreinte Carbone : Évaluation de la consommation électrique par requête et cycle de vie du modèle.
- Éthique, Métacognition & Biais : Identifier les 4 pièges cognitifs et garantir la supervision critique Human-in-the-Loop.
- Feuille de Route Opérationnelle 2026 : Le cycle méthodologique d'industrialisation en 4 étapes pour l'ingénieur et le technicien.

Régulation Européenne : Le Règlement AI Act (2024-2026)


Cadre juridique contraignant et classification par niveau de risque

- Réglementation pionnière : Règlement (UE) 2024/1689 adopté le 13 juin 2024, avec sanctions financières pouvant atteindre 35 millions d'euros ou 7% du CA.
- Approche fondée sur le risque : 4 catégories de risques allant de l'interdit pur au risque minimal, avec exigences proportionnées à l'impact humain.
- Impacts systèmes industriels : Les IA intégrées aux machines-outils de sécurité, à la robotique collaborative et au tri RH sont classées 'Haut Risque'.
- Obligations constructeurs : Analyse de risques continue, gouvernance des données d'entraînement, robustesse cyber, traçabilité et marquage CE obligatoire.

Sources & Références Officielles :

- › Journal Officiel de l'UE : Règlement (UE) 2024/1689 du 13 juin 2024 — <https://eur-lex.europa.eu/eli/reg/2024/1689/oj>
- › Commission Européenne : Bureau Européen de l'IA (AI Office) — <https://digital-strategy.ec.europa.eu/en/policies/ai-office>

LÉGISLATION EUROPÉENNE SUR L'IA (AI ACT — RÈGLEMENT UE 2024/1689)



Pyramide des 4 niveaux de risque du Règlement (UE) 2024/1689 (AI Act)

Souveraineté Numérique & Modèles Ouverts (Open-Weights)

Maîtrise de la propriété intellectuelle et indépendance technologique

- Vulnérabilités du Cloud propriétaire : Risque d'extraterritorialité juridique (Cloud Act), fuite potentielle de secrets de fabrication et dépendance tarifaire.
- L'alternative Open-Weights : Poids de modèles librement téléchargeables (Mistral, Llama, Qwen) offrant des performances comparables aux modèles fermés.
- Déploiement On-Premise Air-Gapped : Hébergement local sur serveurs internes à l'usine, totalement déconnectés d'Internet (étanchéité des données).
- Personnalisation et souveraineté : Fine-tuning sans restriction sur les lexiques métiers internes, coût marginal par requête nul en phase de croisière.

Sources & Références Officielles :

- › Mistral AI : Modèles Ouverts Européens & Architecture Mixtral — <https://mistral.ai/news/>
- › ANSSI : Recommandations de sécurité pour l'IA générative (2024) — <https://www.ssi.gouv.fr/>

SOUVERAINETÉ NUMÉRIQUE & MODÈLES OUVERTS EN INDUSTRIE

CLOUD PROPRIÉTAIRE (AMÉRICAIN) Risques de dépendance & conformité

- Extraterritorialité juridique (Cloud Act US)
- Risque de fuite de propriété intellectuelle
- Dépendance aux tarifs et quotas d'API
- Latence réseau incompatible temps réel usine
- Modèles boîtes noires non auditable

MODÈLES OUVERTS & SOUVERAINS (OPEN-WEIGHTS) Maîtrise totale On-Premise (Usine)

- Hébergement local en réseau étanche (Air-Gapped)
- Modèles européens d'excellence (Mistral AI)
- Modèles ouverts mondiaux (Llama, Qwen)
- Coût par requête nul en régime d'atelier
- Personnalisation sans limite sur lexiques métier

Écosystème des modèles ouverts (Mistral AI, Meta Llama) vs Modèles propriétaires Cloud


Déploiement Local & Frugalité : SLM et Quantification Numérique

Rendre l'IA embarquable sur matériel industriel standard

- L'essor des Petits Modèles (SLM - 1B à 8B) : Modélisation optimisée sur données d'entraînement filtrées, rivalisant avec les anciens mastodontes.
- Mécanisme de Quantification (AWQ, GGUF, GPTQ) : Réduction de précision des poids de FP16 (16 bits) à INT4 (4 bits) avec perte de fidélité inférieure à 1%.
- Diviser l'empreinte mémoire par 4 : Un modèle 7B en FP16 nécessite 14 à 16 Go de VRAM ; quantifié en 4-bit, il s'exécute sur seulement 4.5 Go de VRAM.
- Embarquement Edge usine : Exécution fluide sur cartes d'automatisme (Nvidia Jetson, NPU) ou PC d'atelier d'entrée de gamme sans abonnement cloud.

Sources & Références Officielles :

- › Dettmers et al. (Washington Univ.) : QLoRA: Efficient Finetuning (arXiv:2305.14314) — <https://arxiv.org/abs/2305.14314>
- › Microsoft Research : The Phi-3 Technical Report (arXiv:2404.14219) — <https://arxiv.org/abs/2404.14219>



Comparatif d'empreinte VRAM : Impact de la quantification 4-bit / 8-bit sur SLM et LLM


Enjeux Énergétiques & Bilan Carbone de l'IA Industrielle

Mesurer et optimiser le coût électrique du cycle de vie des modèles

- Dominance de l'inférence : Contrairement aux idées reçues, 75% à 85% de l'empreinte énergétique d'une IA provient de son usage quotidien en production.
- Échelle de consommation : Requête web classique (~0.3 Wh), LLM 7B local quantifié (~1.2 Wh), modèle Cloud 70B (~4.5 Wh), modèle de raisonnement complexe (~18 Wh).
- Principe de frugalité : Adapter rigoureusement la taille du modèle à la complexité de la tâche (ne pas allouer un LLM 70B à une simple classification d'alertes).
- Indicateurs RSE & Usine Verte : Prise en compte du PUE (Power Usage Effectiveness) des baies serveurs et du coût en kWh par pièce contrôlée.

Sources & Références Officielles :

- › Luccioni et al. (Hugging Face) : Power Hungry Processing (arXiv:2311.16863) — <https://arxiv.org/abs/2311.16863>
- › Agence Internationale de l'Énergie (IEA) : Electricity Report 2024: Data Centres & AI — <https://www.iea.org/reports/electricity-2024>



Consommation électrique par requête (Wh) et répartition du cycle de vie IA (IEA / Luccioni 2024)

Éthique & Métacognition : Les 4 Pièges Cognitifs de l'Ingénieur

Penser avec la machine sans renoncer à l'esprit critique

- Biais d'automatisation : Tendance psychologique à déléguer aveuglément la décision à l'algorithme sans vérification contradictoire sur pièce réelle.
- Illusion de compétence : L'éloquence du langage d'un modèle génère une fausse impression d'omniscience technique, masquant les failles physiques.
- Biais de confirmation renforcé : Risque d'utiliser l'IA pour conforter une intuition erronée sans tester les conditions aux limites de sécurité.
- Atrophie des compétences : Perte progressive de savoir-faire critique si les analyses de panne fondamentales ne sont plus pratiquées manuellement.
- Posture de l'Ingénieur : 'Penser contre soi-même' — imposition stricte d'un protocole de validation indépendante (Human-in-the-Loop).

Sources & Références Officielles :

- › Parasuraman & Manzey : Complacency and Bias in Human Automation (Human Factors 2010) — <https://doi.org/10.1177/0018720810376055>
- › AFNOR Spec IA (2024) : Guide de fiabilité des systèmes à base d'IA — <https://www.afnor.org/>

LES 4 PIÈGES COGNITIFS DE L'INGÉNIEUR FACE À L'IA

Matrice des biais décisionnels et contre-mesures de supervision critique

1. BIAIS D'AUTOMATISATION Délégation aveugle de la décision • Confiance excessive dans le résultat du modèle • Négligence du contrôle physique contradictoire • Risque critique sur sécurités machines Garde-fous : Procédure de double vérification humaine obligatoire	2. ILLUSION DE COMPÉTENCE Éloquence confondue avec exactitude • Le LLM s'exprime avec une autorité trompeuse • Masquage des failles physiques sous un style fluide • Hallucinations subtiles sur normes ISO Garde-fous : Ancrage RAG strict sur manuels vérifiés
3. BIAIS DE CONFIRMATION Instrumentalisation de l'IA • Utiliser l'IA pour valider son intuition initiale • Omission de tester les cas limites de rupture • Prompt orienté confirmant l'erreur de calcul Garde-fous : Prompting d'avocat du diable (challenge critique)	4. ATROPHIE DES COMPÉTENCES Perte d'expertise fondamentale • Incapacité progressive à diagnostiquer sans outil • Dégradation des connaissances métier de base • Dépendance algorithmique irréversible Garde-fous : Maintien d'ateliers manuels 'sans IA' réguliers

Matrice des 4 pièges cognitifs face à l'IA et contre-mesures méthodologiques

Synthèse & Feuille de Route Opérationnelle de l'Ingénieur 2026

Cycle méthodologique en 4 étapes pour industrialiser un projet d'IA


- Étape 1 - Cadrage & ROI : Qualification du besoin métier, calcul de retour sur investissement industriel et classification préliminaire de risque AI Act.
- Étape 2 - Architecture Souveraine : Sélection du modèle (SLM ou LLM spécialisé), choix du runtime local (Ollama / vLLM) et isolation réseau usine.
- Étape 3 - Intégration RAG & MCP : Raccordement sécurisé à la documentation technique, protocoles d'automatisme (OPC-UA) et supervision agentique.
- Étape 4 - Gouvernance & Cycle de Vie : Documentation technique obligatoire, surveillance de la dérive du modèle (Drift), formation des équipes et audit continu.

Sources & Références Officielles :

- › Organisation Internationale de Normalisation : ISO/IEC 42001:2023 - Management de l'IA — <https://www.iso.org/standard/81230.html>
- › Ministère de l'Économie et des Finances : Stratégie Nationale pour l'IA Industrielle — <https://www.entreprises.gouv.fr/>

FEUILLE DE ROUTE MÉTHODOLOGIQUE DE L'INGÉNIEUR 2026

Cycle d'industrialisation conforme aux normes AFNOR Spec IA et AI Act européen



Feuille de route en 4 étapes : Du cadrage ROI à la gouvernance conforme AI Act

Références :

Références Fondamentales & Générales

- Conférence Yann LeCun (Collège de France) : Atteindre l'intelligence humaine
- Stéphane Roder (Eyrolles) : Guide pratique de l'IA dans l'entreprise
- CNRS / FIDLE : Introduction approfondie au Deep Learning
- Collège de France : Colloque L'IA et ses défis scientifiques et sociétaux
- Université de Genève & Inspé : Guides pratiques d'accompagnement à l'IA
- DGE / Ministère : Décryptage des opportunités de l'IA pour les entreprises

Références Techniques & Normes 2024-2026

- Règlement (UE) 2024/1689 (AI Act) : Cadre légal et exigences des systèmes à haut risque
- ISO/IEC 42001:2023 : Système de management de l'intelligence artificielle (SMIA)
- Vaswani et al. (2017) : 'Attention Is All You Need' — Mécanisme Transformer fondateur
- Anthropic (2024) : Spécification du standard ouvert MCP (Model Context Protocol)
- AFNOR Spec IA (2024) : Bonnes pratiques d'ingénierie et de robustesse des modèles
- ANSSI (2024) : Guide de sécurité pour l'IA générative et souveraineté des données
- Luccioni et al. / AIE (2024) : Bilan énergétique et mesure de l'empreinte carbone de l'IA