Former au Discernement et à l’Esprit Critique à l’Ère des IA Génératives :

De l'Illusion de Fluidité à l'Ingénierie de l'Externalisation Vertueuse

Introduction : Le Changement de Paysage Cognitif et le Paradoxe Technologique

L'intégration massive des intelligences artificielles génératives (IAG), et plus particulièrement des grands modèles de langage (LLM), dans les environnements d'apprentissage marque une rupture épistémologique et cognitive sans précédent dans l'histoire de la transmission des savoirs. L'ingénierie pédagogique contemporaine se trouve confrontée à un paradoxe fondamental : ces outils offrent une capacité inédite de traitement de l'information et de production de contenus sophistiqués, tout en menaçant intrinsèquement les processus mêmes qui sous-tendent l'apprentissage profond et le développement de la pensée critique. L'arrivée de ces technologies ne se résume pas à l'ajout d'un nouvel outil dans la trousse de l'apprenant ; elle redéfinit les frontières de la cognition humaine et modifie la nature même de l'effort intellectuel.

Les LLM introduisent une forme de délégation massive des tâches intellectuelles. Chercher des sources, résumer des concepts ardus, rédiger des synthèses, structurer un raisonnement dialectique ou encore proposer des arguments contradictoires sont désormais des opérations exécutables en quelques secondes par une machine. Cette délégation s'inscrit dans ce que la psychologie cognitive et la philosophie de l'esprit nomment le *cognitive offloading* (l'externalisation cognitive), c'est-à-dire le fait de s'appuyer sur des artefacts environnementaux ou technologiques pour réaliser des opérations mentales qui nécessiteraient autrement un effort interne soutenu. Si l'externalisation n'est pas un phénomène nouveau en soi — l'usage de l'écriture, de la calculatrice ou des moteurs de recherche en sont des exemples historiques —, l'échelle, la rapidité et la nature de la délégation permise par l'IA générative sont radicalement différentes. L'outil ne se contente plus de stocker l'information, il la structure, l'articule et la présente sous une forme finie et rhétoriquement aboutie.

Les recherches récentes en sciences cognitives démontrent que ces outils tendent à améliorer significativement la performance apparente et immédiate de l'apprenant, tout en affaiblissant drastiquement la profondeur du traitement cognitif. Lorsque l'algorithme automatise les phases les plus exigeantes du travail intellectuel (l'analyse de données hétérogènes, la mise en forme logique, la reformulation syntaxique), l'apprenant réduit inévitablement son effort d'élaboration personnelle. Cette dynamique nuit invariablement à la mémorisation à long terme, au transfert de compétences vers de nouveaux contextes et à l'exercice autonome du discernement. Il s'agit d'une atrophie invisible, masquée par l'excellence du produit final généré par la machine.

Face à ce constat, il devient impératif de prendre un recul critique et profondément scientifique sur les effets de ces technologies au sein des pratiques de formation. La réponse institutionnelle ne peut se limiter à une régulation punitive ou à une interdiction, d'ailleurs techniquement inapplicable. Ce rapport de recherche exhaustif explore les biais, les illusions d'expertise et le confort cognitif induits par la fluidité des réponses algorithmiques, tant chez les apprenants que chez les formateurs. En mobilisant les neurosciences, la psychologie de l'apprentissage et les modèles avancés d'ingénierie pédagogique, cette analyse propose des stratégies didactiques concrètes pour repenser la formation.

L'objectif est de transformer l'IA, souvent perçue comme un "oracle" favorisant la passivité, en un véritable "partenaire dialogique", permettant d'atteindre une "externalisation vertueuse" au sein d'environnements éducatifs complexes.

Le Piège Doré de la Fluidité et l'Illusion d'Expertise

Pour comprendre l'impact cognitif des IA génératives, il est essentiel de disséquer la nature de leurs productions et la manière dont le cerveau humain les réceptionne. La caractéristique la plus trompeuse des modèles tels que GPT-4 ou Claude réside dans leur capacité à générer une prose parfaite, dépourvue des hésitations inhérentes à la pensée humaine en cours de construction.

L'Optimisation Probabiliste et l'Apparence de Maîtrise

Les textes générés par les LLM se caractérisent par une fluidité syntaxique exceptionnelle, une structure argumentative d'une clarté redoutable et une rhétorique hautement persuasive. Ces systèmes miment avec une précision troublante les productions textuelles d'experts académiques ou professionnels. Toutefois, cette apparence de maîtrise repose sur un mécanisme d'optimisation statistique purement probabiliste. Les modèles d'apprentissage profond prédisent l'occurrence des mots (ou *tokens*) suivants en maximisant la cohérence locale et la vraisemblance contextuelle, sur la base des milliards de paramètres acquis lors de leur entraînement. Il n'y a, au sein du réseau de neurones artificiels, aucune compréhension sémantique ontologique, ni aucun ancrage dans une réalité factuelle ou expérientielle.

Cette architecture algorithmique privilégie systémiquement la *cognitive ease* (l'aisance cognitive ou la fluidité de traitement) au détriment de la véracité stricte. Par conséquent, une requête formulée par un apprenant, même vague, ambiguë ou conceptuellement erronée, aboutira presque invariablement à un texte bien structuré, intégrant un vocabulaire technique approprié et des transitions logiques impeccables. Cette priorisation absolue de la forme, inhérente au design probabiliste, engendre fréquemment des hallucinations. Ces dernières se manifestent sous la forme d'affirmations factuellement erronées, de fausses références bibliographiques, de théorèmes inexistants ou de causalités inventées, présentées avec le même ton assuré, péremptoire et professoral que des vérités scientifiques validées par les pairs.

L'Illusion d'Expertise à travers le Prisme des Systèmes de Pensée

La fluidité générée par les LLM conforte l'utilisateur dans une impression d'expertise illusoire, activant des mécanismes psychologiques documentés de longue date. Les travaux fondateurs de Daniel Kahneman sur l'économie de l'attention et les modes de traitement de l'information fournissent une grille d'analyse indispensable pour appréhender ce phénomène.

Mode de Traitement (Modèle de Kahneman)	Caractéristiques Fondamentales	Interaction Spécifique avec les IA Génératives
Système 1	Opération rapide, intuitive, heuristique, automatique, émotionnelle et très peu coûteuse en énergie métabolique.	Fortement stimulé par la fluidité lexicale, la bonne syntaxe et le ton assuré de l'IA. Le cerveau accepte l'information comme "vraie" en l'absence de dissonance cognitive de surface, générant un sentiment d'expertise par procuration.
Système 2	Opération lente, analytique, délibérée, demandant un effort conscient, évaluant les probabilités et la logique profonde.	Court-circuité et maintenu en veille par la structure parfaite de l'output algorithmique. L'effort analytique n'est pas déclenché car le texte ne présente pas de frictions formelles ou d'incohérences immédiatement perceptibles.

L'allure "universitaire" d'une réponse générée par l'IA — caractérisée par un plan apparent, la présence de références croisées et un lexique spécialisé — active de puissants biais cognitifs chez l'apprenant. Le biais d'autorité pousse l'étudiant à faire confiance à la "voix experte" de la machine, lui prêtant une infaillibilité qu'elle ne possède pas. Parallèlement, le biais de crédulité l'amène à sous-estimer drastiquement la probabilité d'erreur factuelle ou logique lorsque la forme du message est esthétiquement soignée et grammaticalement irréprochable. Des études empiriques en psychologie cognitive démontrent que cette aisance cognitive agit comme un signal faussement positif de vérité, créant une véritable "illusion de vérité" (illusion of truth) où la cohérence interne et la beauté du texte supplantent l'évaluation critique et laborieuse de son contenu sémantique.

Neurobiologie de l'Évaluation : Le Contournement de la Boucle d'Apprentissage

Le danger de cette fluidité algorithmique s'observe jusqu'au niveau neurobiologique. L'architecture cérébrale humaine dispose de mécanismes de détection des conflits cognitifs, principalement gouvernés par le cortex cingulaire antérieur (ACC). Cette région du cerveau est responsable de la détection des erreurs, des anomalies, des incohérences et des conflits dans le traitement de l'information environnementale. Lorsqu'un apprenant lit un texte brouillon, contenant des sauts logiques, des contradictions apparentes ou une syntaxe alambiquée, l'ACC détecte un conflit et envoie un signal d'alerte. Ce signal engage alors le cortex préfrontal (siège du Système 2) pour résoudre le conflit par une analyse délibérée, un retour en arrière dans la lecture ou une vérification externe. Ce processus neurologique de résolution de conflit est le moteur fondamental de l'apprentissage profond.

Cependant, les systèmes d'IA actuels, optimisés par apprentissage par renforcement à partir de rétroactions humaines (RLHF), sont conçus pour offrir une douceur linguistique maximale et une aisance cognitive absolue. La haute plausibilité et la fluidité des réponses algorithmiques génèrent un signal de conflit beaucoup plus faible, voire totalement inexistant, au niveau de l'ACC. En minimisant la dissonance cognitive dès la première interaction, les LLM affaiblissent l'intégralité de la boucle neurobiologique d'apprentissage basée sur la résolution de conflits. L'étudiant ressent une sensation de fluidité et d'évidence qui est faussement interprétée par le cerveau comme une maîtrise

intériorisée du sujet. L'agrément immédiat de la lecture supplante la nécessité de la confrontation intellectuelle, installant l'apprenant dans une posture de consommateur béat d'informations plausibles mais non interrogées. L'IA se présente non pas comme un être agissant doté d'intentionnalité, mais comme une machine à générer des illusions d'agentivité, créant une déférence épistémique dangereuse pour la formation de l'esprit scientifique.

L'Atrophie Invisible, la Paresse Cognitive et le Confort

La fluidité des modèles algorithmiques engendre ce que la littérature scientifique qualifie de "paresse cognitive" ou d'externalisation excessive. Face à une tâche d'apprentissage complexe — qu'il s'agisse d'analyser un corpus de textes historiques, de rédiger une synthèse philosophique ou de comparer des paradigmes économiques —, l'apprenant est confronté à des charges cognitives substantielles. L'IA générative intervient ici comme un solvant universel de la friction intellectuelle.

La Réduction de la Charge Cognitive et l'Offloading

Dans la théorie de l'apprentissage, on distingue la charge cognitive intrinsèque (liée à la difficulté inhérente au contenu) et la charge cognitive essentielle ou germane (liée à l'effort d'élaboration, de création de schémas mentaux et d'intégration des nouvelles connaissances dans la mémoire à long terme). Lorsqu'un apprenant délègue la structuration de sa pensée à un LLM, ces deux charges sont drastiquement réduites. L'IA absorbe la complexité de la tâche, offrant une solution clé en main qui ne nécessite plus l'engagement des processus cognitifs d'ordre supérieur.

Les analyses quantitatives récentes mettent en lumière les conséquences délétères de cette délégation lorsqu'elle devient systématique. Des études à grande échelle montrent une corrélation négative significative entre l'utilisation fréquente d'outils d'IA générative et le maintien des capacités de pensée critique. L'offloading cognitif agit comme un facteur médiateur majeur dans cette atrophie. Plus un étudiant accorde de confiance à la justesse apparente de l'outil, moins il exerce son esprit critique et moins il investit d'efforts dans la vérification des sources, l'évaluation des biais ou la reformulation des concepts. Les apprenants qui sur-utilisent l'IA pour des tâches d'analyse développent une atrophie progressive de leurs compétences en résolution de problèmes complexes. Ils peinent à évaluer de manière indépendante des informations nuancées ou contradictoires.

Le doute méthodique, composante essentielle de la démarche scientifique et citoyenne, qui consiste à questionner l'origine des sources, à identifier les présupposés idéologiques et à traquer les biais, s'évapore. Ce doute est remplacé par une adhésion passive à l'output algorithmique, perçu comme une autorité neutre et omnisciente. On observe une "déqualification" (deskilling) où la performance immédiate de l'étudiant (la note obtenue à un devoir généré par IA) masque un effondrement de ses compétences réelles. Il se produit un paradoxe de la performance supervisée : l'étudiant finit son travail beaucoup plus vite, avec une qualité syntaxique supérieure, mais déclare lui-même ne pas avoir véritablement compris ou retenu les concepts manipulés par la machine.

La Symétrie du Piège : L'Impact sur les Formateurs

Ce phénomène d'atrophie et de confort cognitif ne se limite pas au public apprenant ; il affecte symétriquement les professionnels de l'éducation et de l'ingénierie pédagogique. Soumis à des contraintes de temps et de productivité, les formateurs eux-mêmes subissent l'attraction du confort algorithmique. L'utilisation d'un LLM pour concevoir des syllabus, rédiger des plans de cours, générer

des activités d'évaluation (comme des questionnaires à choix multiples) ou créer des grilles critériées entraîne un gain de temps indéniable.

Cependant, cette délégation de l'ingénierie didactique favorise une uniformisation pédagogique préoccupante. En s'appuyant aveuglément sur les propositions de l'IA, la conception de la formation s'aligne sur les standards statistiques de l'outil. La personnalisation, la sensibilité aux besoins idiosyncratiques d'un groupe d'apprenants spécifique, et la prise en compte des contextes territoriaux se diluent dans une moyenne algorithmique. De plus, les formateurs risquent de propager, souvent à leur insu, les biais culturels, linguistiques et épistémologiques inhérents aux corpus d'entraînement des modèles, qui surreprésentent massivement les perspectives anglo-saxonnes et occidentales au détriment d'une pluralité de pensées. L'expertise didactique, qui réside précisément dans la capacité à créer des étayages complexes et adaptés, se trouve menacée par la standardisation fluide de la machine.

La Réhabilitation de la Friction par les Difficultés Désirables

Face au piège du confort cognitif induit par les IA génératives, il est crucial de réinterroger la définition même de l'apprentissage à l'aune des sciences cognitives. La réponse aux défis posés par l'externalisation excessive réside dans les travaux fondateurs du psychologue Robert Bjork sur la théorie des "difficultés désirables" (desirable difficulties).

La Dichotomie Fondamentale : Apprentissage versus Performance

Le cœur de la théorie de Bjork repose sur une distinction stricte et contre-intuitive entre la *performance* et l'*apprentissage*. La performance désigne l'exécution immédiate, observable et mesurable d'une tâche lors de la phase d'acquisition. L'apprentissage, en revanche, désigne une modification permanente de l'architecture cognitive, caractérisée par la rétention à long terme de l'information et, surtout, par la capacité de transfert des connaissances et des compétences vers des contextes inédits.

Les environnements éducatifs qui semblent les plus faciles, fluides et confortables à court terme — typiquement ceux où une IA générative agit comme un tuteur surprotecteur, un correcteur invisible ou un rédacteur fantôme — maximisent artificiellement la performance immédiate. L'étudiant produit un travail impeccable en un temps record, procurant une satisfaction immédiate tant à l'apprenant qu'à l'évaluateur. Toutefois, ces mêmes conditions d'aisance produisent les traces mnésiques les plus fragiles et les schémas cognitifs les plus superficiels. L'illusion de fluidité empêche l'encodage profond.

À l'inverse, les conditions pédagogiques qui introduisent volontairement des frictions, des lenteurs, des obstacles cognitifs, des tâtonnements et une part de frustration — ce que Bjork qualifie de difficultés désirables — sont celles qui génèrent l'apprentissage le plus robuste, durable et transférable. L'effort déployé pour surmonter ces difficultés force le cerveau à créer des connexions synaptiques multiples, ancrant l'information de manière pérenne. La recherche documentaire itérative, la reformulation laborieuse d'un concept abstrait, la résolution de contradictions entre différentes sources et l'effort d'auto-explication sont des processus métaboliquement coûteux, mais absolument indispensables à la structuration de l'intellect.

Les Quatre Piliers des Difficultés Désirables Face à l'IA

L'usage non régulé et irréfléchi de l'IA générative court-circuite systématiquement les stratégies identifiées par la recherche comme essentielles à la consolidation mnésique :

Stratégie de Difficulté Désirable (R. Bjork)	Mécanisme Cognitif Sollicité	Destruction par l'Usage Non Régulé de l'IA Générative
L'Espacement (Spacing Effect)	Distribuer l'apprentissage et les révisions dans le temps pour forcer le cerveau à consolider les souvenirs entre les sessions.	L'IA permet la génération de réponses exhaustives et instantanées juste avant une échéance, favorisant un "bachotage" synthétique d'urgence qui annule tout effet d'espacement.
L'Entrelacement (Interleaving)	Alterner différents types de problèmes ou de disciplines lors d'une même session pour améliorer la capacité de discrimination cognitive.	L'IA a tendance à fournir, sur requête, des blocs d'informations monolithiques, linéaires et hautement catégorisés, réduisant la nécessité pour l'apprenant de faire des liens transversaux.
La Pratique de la Récupération (Retrieval Practice)	L'effort actif, parfois douloureux, de rappeler une information de sa mémoire sans support externe, renforçant ainsi la force de récupération (retrieval strength).	C'est le point d'impact le plus destructeur. En fournissant la réponse exacte à la moindre sollicitation, l'IA dispense totalement l'étudiant de l'effort de récupération interne, atrophiant sa capacité d'ancrage mémoriel.
La Génération (Generation Effect)	Tenter de produire une réponse, une hypothèse ou de résoudre un problème avant même d'avoir reçu l'instruction complète ou la solution.	Déléguer l'idéation ou la rédaction du premier brouillon à l'IA prive l'apprenant de la phase cruciale et formatrice de structuration initiale de sa propre pensée, le reléguant à un rôle de simple relecteur.

L'ingénierie pédagogique contemporaine ne doit pas chercher à supprimer l'IA, mais à l'orchestrer de manière à réintroduire ces difficultés désirables de façon hybride. Il s'agit de concevoir des scénarios didactiques où la machine ne supprime pas l'effort de compréhension, mais l'accompagne, forçant l'apprenant à s'engager dans une lutte cognitive productive (productive struggle). L'IA doit devenir un outil qui complexifie l'analyse plutôt qu'un outil qui simplifie la réponse.

Prendre un Recul Pédagogique : Repenser l'Ingénierie avec ADDIE et l'AI-TPACK

Comment, en tant qu'ingénieur pédagogique et concepteur de dispositifs de formation, créer des environnements qui tirent parti de la puissance analytique et syntaxique des LLM tout en préservant jalouseusement le développement cognitif et l'intégrité intellectuelle des apprenants? La solution exige une reconfiguration profonde des cadres théoriques et méthodologiques traditionnels de la conception pédagogique.

L'Évolution des Compétences du Formateur : Le Cadre AI-TPACK

L'intégration pertinente de l'IA exige avant tout une refonte des compétences des formateurs et des ingénieurs eux-mêmes, modélisée par le récent cadre AI-TPACK (Artificial Intelligence - Technological Pedagogical Content Knowledge). Historiquement centré sur l'intersection entre la technologie, la

pédagogie et le contenu disciplinaire, ce modèle s'augmente pour répondre aux défis spécifiques des IA génératives.

Le cadre AI-TPACK stipule que la simple maîtrise technique de l'outil (savoir rédiger un prompt basique, catégorisé comme AI-TK) est totalement insuffisante pour éviter les écueils de l'externalisation. Cette compétence technique doit impérativement s'hybrider avec des dimensions critiques et didactiques supérieures :

- **La Connaissance du Contenu à l'ère de l'IA (AI-CK) :** Il s'agit de la capacité du formateur à comprendre comment l'IA représente, structure et parfois déforme le savoir spécifique de sa discipline. Le formateur doit être capable d'identifier les limites épistémiques, les hallucinations récurrentes et les biais algorithmiques inhérents aux réponses générées dans son champ d'expertise. Cela requiert une solide littératie algorithmique et scientifique.
- **La Connaissance Pédagogique de l'IA (AI-PK) :** C'est l'aptitude à savoir sélectionner, adapter et scénariser l'usage des LLM pour créer des expériences d'apprentissage qui favorisent le discernement. Cela implique de savoir quand autoriser l'outil pour stimuler l'idéation, et quand le restreindre pour forcer la pratique de la récupération (retrieval practice). L'AI-PK englobe également la gestion de l'environnement éthique, la protection des données des apprenants et la calibration de la charge cognitive.

La Révision Algorithmique du Modèle ADDIE

Le modèle canonique de conception de systèmes d'apprentissage ADDIE (Analyse, Design, Développement, Implémentation, Évaluation) nécessite une adaptation structurelle itérative pour intégrer les IAG de manière réflexive.

1. **Analyse : L'Audit des Risques Cognitifs et la Taxonomie de Bloom Révisée.**

   Dès la phase d'identification des besoins, l'ingénieur pédagogique doit cartographier les risques de *cognitive offloading* inhérents aux tâches qui seront demandées aux apprenants. Il convient de mobiliser une Taxonomie de Bloom révisée pour l'ère de l'automatisation intellectuelle. Les compétences de bas et moyen niveaux (mémoriser des faits, comprendre des concepts simples, restituer des définitions, appliquer des formules standard) étant massivement et instantanément exécutables par l'IA, l'analyse des objectifs d'apprentissage doit reprioriser drastiquement le curriculum vers les compétences cognitives d'ordre supérieur : évaluer la fiabilité d'une information, juger de la pertinence d'un argumentaire, synthétiser des sources hétérogènes et contradictoires, et créer des concepts originaux. L'audit doit également intégrer une couche d'évaluation éthique (ethical audit) pour anticiper les biais de représentation que l'IA pourrait introduire dans le parcours de formation.

2. **Design (Conception) : La Scénarisation Hybride.**

   Les parcours et scénarios d'apprentissage doivent être conçus d'emblée de manière hybride. L'IA ne doit jamais être positionnée comme un correcteur invisible ou un rédacteur de substitution. Les dispositifs doivent intégrer des "points de friction désirables" volontaires. Par exemple, concevoir des tâches qui exigent de l'apprenant qu'il contextualise les outputs génériques de l'IA dans une situation locale très spécifique, qu'il les confronte à une réalité de terrain physique, ou qu'il y intègre des considérations éthiques, des dilemmes humains et des

émotions — autant de dimensions complexes, implicites et situées que l'architecture probabiliste de l'IA manipule avec une profonde opacité et superficialité.

3. **Développement : L'Ingénierie des Prompts Critiques et des Scaffolds.**

   Lors de la création du matériel pédagogique, l'ingénieur doit développer des consignes spécifiques (des *prompts* pédagogiques) à destination des apprenants. Ces consignes n'ont pas pour but de guider l'étudiant vers la génération de la "meilleure" réponse algorithmique, mais de générer la matière première qui servira d'objet de critique. (Exemple : "Demandez à l'IA de générer une synthèse justifiant telle politique économique, puis annotez le texte généré pour identifier les trois biais idéologiques majeurs et les omissions factuelles de la machine"). Il est également nécessaire de développer des outils de traçabilité métacognitive, tels que des journaux de bord, pour structurer l'étayage (scaffolding) de la réflexion.

4. **Implémentation : Transparence et Mise en Scène de la Contradiction.**

   Le déploiement de la formation requiert l'établissement de chartes d'usage explicites et transparentes, négociées avec les apprenants, définissant l'intégrité académique à l'ère de l'IA. L'implémentation doit favoriser la mise en scène de confrontations intellectuelles en classe (débats orchestrés entre les propositions de l'IA et l'analyse critique des étudiants, corrections collectives et commentées d'hallucinations algorithmiques) pour désacraliser la machine.

5. **Évaluation : Juger l'Itinéraire Métacognitif, non le Produit Textuel.**

   L'évaluation sommative traditionnelle, centrée sur la livraison d'un produit final écrit (dissertation, mémoire, rapport) réalisé hors de la vue du formateur, est devenue caduque. L'authenticité de la paternité intellectuelle du texte ne pouvant plus être garantie avec une certitude absolue, ni par le jugement humain ni par les logiciels de détection (qui génèrent de nombreux faux positifs), l'ingénierie de l'évaluation doit se déplacer. L'évaluation doit désormais mesurer le processus, la justification épistémologique de l'usage de l'outil, la pertinence des itérations de requêtes (l'historique des prompts), la traçabilité des vérifications effectuées par l'étudiant et la part réelle d'appropriation critique personnelle. Parallèlement, il est impératif de réinvestir massivement dans des modalités d'évaluation non médiées par l'écran : soutenances orales approfondies, débats argumentés en temps réel, et résolution de cas pratiques complexes en environnement contrôlé (sans accès aux IA), afin de garantir que l'apprentissage a bien eu lieu dans les structures cognitives internes de l'étudiant, et non uniquement dans les serveurs de l'entreprise technologique.

L'Externalisation Vertueuse et l'IA comme Partenaire Dialogique

Pour naviguer entre la technophobie stérile et l'adoption aveugle, la recherche en sciences de l'éducation propose de nouveaux cadres conceptuels permettant de redéfinir la relation entre l'apprenant et l'algorithme. Deux concepts émergent comme fondamentaux : l'externalisation vertueuse et le partenaire dialogique.

L'Externalisation Vertueuse (Virtuous Outsourcing)

Les chercheurs en philosophie de l'éducation et en épistémologie, tels que William Gopal et Michael Quinn (2025), introduisent le concept décisif d'"Externalisation Vertueuse" (*Virtuous Outsourcing*) pour encadrer pédagogiquement la délégation cognitive aux IA génératives. Selon cette approche, l'enjeu principal de l'éducation à l'IA ne consiste pas simplement à enseigner aux étudiants *comment* utiliser techniquement un LLM (l'ingénierie de prompt procédurale), mais plutôt à développer leur "caractère cognitif" et leurs vertus intellectuelles (comme la persévérance, l'humilité épistémique et l'honnêteté) pour qu'ils sachent juger *quand*, *pourquoi* et *dans quelles limites* il est approprié de déléguer une tâche intellectuelle à une machine.

Une externalisation est considérée comme vertueuse lorsqu'elle libère des ressources cognitives limitées (attention, mémoire de travail) non pas dans le but de fuir l'effort par paresse intellectuelle, mais dans l'objectif explicite de réinvestir immédiatement cette énergie mentale dans des processus de pensée d'ordre supérieur. Par exemple, déléguer à l'IA la restructuration formelle d'un brouillon ou la recherche de synonymes est vertueux si l'apprenant utilise le temps et l'énergie ainsi gagnés pour affiner la profondeur conceptuelle de son argumentation, croiser des sources divergentes ou intégrer une réflexion éthique complexe. Il s'agit d'une délégation responsable où l'outil étaye (scaffolds) le processus d'apprentissage sans jamais court-circuiter l'agence (agency) et la métacognition de l'étudiant.

Former à cette vertu épistémique implique de rendre visible aux yeux des apprenants la dissociation fondamentale entre l'obtention immédiate d'un produit final (le texte poli généré par la machine) et le lent processus d'apprentissage (la compréhension intériorisée et la transformation des schémas mentaux). Pour illustrer cette prise de conscience, Gopal et Quinn suggèrent des approches pédagogiques innovantes mobilisant la fiction et la culture populaire. Ils proposent par exemple d'utiliser l'analyse d'œuvres cinématographiques abordant la mémoire et l'identité (comme le film *Memento* de Christopher Nolan) pour amener les étudiants à identifier ce qu'ils nomment les "points de choix délégatifs" (*delegative choice points*). L'analyse de scénarios de fiction permet aux apprenants de visualiser de manière distanciée et dramatique les conséquences potentiellement désastreuses d'une délégation inappropriée ou excessive de ses propres fonctions cognitives, mnésiques et critiques à une entité externe, facilitant ainsi la transposition de cette réflexion critique à leur propre usage des LLM.

Dans le contexte concret de l'ingénierie pédagogique, l'externalisation vertueuse se traduit par la mise en place de dispositifs exigeant une réflexivité constante. Cela prend la forme de grilles d'auto-évaluation métacognitives où l'étudiant doit explicitement documenter et justifier pourquoi il a choisi de recourir à l'IA pour telle étape spécifique de son travail, quels garde-fous il a mis en place pour vérifier la véracité des outputs algorithmiques, et, tout aussi crucial, pourquoi il a délibérément choisi de se passer de l'IA pour réaliser d'autres étapes de son raisonnement nécessitant une authenticité humaine.

L'IA comme Partenaire Dialogique (Dialogic Partner)

Pour dépasser la conception réductrice et dangereuse de l'IA générative perçue comme un "oracle" infaillible et omniscient (une posture d'autorité qui renforce la soumission cognitive), le théoricien de l'éducation Rupert Wegerif propose un changement de paradigme conceptuel : intégrer l'IA comme

un "partenaire dialogique" (*dialogic partner*) évoluant au sein d'un "espace dialogique" (*dialogic space*).

S'appuyant sur les traditions philosophiques et socioculturelles (de Socrate à Bakhtine), Wegerif postule que l'éducation véritable n'est pas un processus linéaire de transfert d'informations d'une entité qui "sait" vers une entité qui "ne sait pas". L'éducation est fondamentalement un processus d'engagement dans des dialogues continus où la signification, la compréhension et le discernement sont co-construits par la confrontation de perspectives multiples et souvent asymétriques.

Bien que les LLM soient dépourvus de conscience, d'intentionnalité véritable ou de compréhension sémantique interne, leur architecture probabiliste leur confère une capacité inégalée à simuler instantanément une multitude de rôles (personas), à générer des perspectives alternatives inattendues et à formuler des contre-arguments structurés. Wegerif soutient que l'IA générative peut ainsi incarner une forme fascinante d'"altérité générative" (*generative alterity*). Cette altérité non-humaine, de par son caractère imprévisible et sa capacité à synthétiser des vastes pans de la culture humaine, introduit des réponses qui peuvent s'avérer surprenantes, déstabilisantes, voire volontairement provocatrices. Ces "chocs" cognitifs agissent comme de puissants catalyseurs de réflexion pour l'apprenant, le forçant à sortir de ses biais de confirmation et à réévaluer ses propres positions.

Dans cette optique "post-formelle" et "trialogique" , l'ingénierie pédagogique doit structurer des interactions homme-machine complexes. Il ne s'agit plus de demander à l'IA de fournir "la" réponse finale à un problème, mais de l'utiliser comme un contradicteur socratique infatigable. L'enseignant orchestre des scénarios où l'IA pose des questions maïeutiques à l'apprenant, souligne les failles logiques de son premier jet, ou lui offre simultanément trois hypothèses conceptuelles divergentes que l'étudiant aura la charge d'arbitrer, d'évaluer et de défendre. L'apprenant est ainsi élevé au rang d'évaluateur critique et de producteur actif de sens, exploitant la capacité de la machine à générer de la variance pour enrichir sa propre délibération intellectuelle, contribuant ainsi au développement d'une véritable "intelligence collective" hybride.

Déploiement Territorial et Innovations Didactiques : Le Cas de la Région Académique Bourgogne-Franche-Comté

La traduction de ces concepts ingénieriques et théoriques complexes (externalisation vertueuse, partenaire dialogique, IA-TPACK) en réalités institutionnelles, administratives et pédagogiques s'observe de manière particulièrement structurée au sein de la région académique Bourgogne-Franche-Comté (BFC). L'approche volontariste de ce territoire illustre comment une institution éducative peut organiser méthodiquement l'acculturation à l'intelligence artificielle, en esquivant les écueils jumeaux du rejet technophobe conservateur et de la fascination technosolutionniste aveugle.

Le Cadre d'Usage Institutionnel : Éthique, Sobriété et Intégrité

La DRANE (Délégation Régionale Académique au Numérique pour l'Éducation) de Bourgogne-Franche-Comté a piloté et mis en application un cadre d'usage de l'IA générative particulièrement rigoureux, centré sur la transparence, l'exercice de l'esprit critique et la protection de la communauté éducative. Ce cadre directeur stipule d'emblée un principe pédagogique fondamental : le recours aux IA génératives n'est autorisé et justifié que lorsqu'une plus-value pédagogique réelle et démontrable est avérée, interdisant de fait l'usage de la technologie pour elle-même.

D'un point de vue éthique et juridique, le cadre de la BFC impose des règles de protection strictes. Il est formellement interdit aux enseignants et aux élèves de saisir des données personnelles, des informations confidentielles ou des productions protégées par le droit d'auteur dans les interfaces des IA grand public (dont les modèles économiques reposent souvent sur la réutilisation opaque des données d'entraînement). Seules les données déjà publiques (textes officiels, œuvres du domaine public, statistiques anonymisées) sont jugées acceptables pour alimenter les *prompts*. En outre, l'institution introduit une dimension novatrice de responsabilité environnementale : le cadre enjoint les personnels à prendre conscience de l'impact énergétique massif et du coût écologique de calcul inhérents à chaque requête adressée à un LLM. Il préconise explicitement de renoncer à l'usage de l'IA générative si une solution numérique plus sobre (telle qu'une simple recherche par mots-clés sur un moteur web classique) s'avère suffisante pour répondre au besoin informationnel.

Sur le plan de l'ingénierie pédagogique, le cadre établit un principe de progressivité du développement cognitif : la manipulation directe et autonome d'interfaces d'IA générative par les élèves n'est pas autorisée avant la classe de 4e (au collège). Avant cet âge, l'approche se limite à une sensibilisation théorique aux concepts de l'IA et à ses enjeux sociétaux. Au collège, l'usage devient autorisé mais demeure strictement encadré, limité et médié par l'enseignant au sein de la classe. Ce n'est qu'au lycée que l'usage autonome est permis, tout en restant inscrit dans un scénario d'apprentissage défini.

Concernant la question névralgique de l'évaluation, le cadre régional prend une position ferme et pragmatique. D'une part, l'utilisation d'une IA générative pour réaliser un devoir sans l'autorisation explicite du professeur et, surtout, sans qu'un travail personnel d'appropriation, d'analyse et de reformulation ne soit démontrable, constitue catégoriquement une fraude académique. D'autre part, et c'est une orientation didactique forte, l'institution déconseille formellement aux enseignants de s'en remettre aux logiciels de "détection" automatique de textes générés par IA, arguant de leur manque de fiabilité technique avéré (risque élevé de faux positifs discriminant les élèves). Cette directive force concrètement les ingénieurs pédagogiques et les enseignants à réinventer les modalités d'évaluation, en délaissant la restitution de contenus formatés au profit de l'évaluation des processus de raisonnement, des capacités de résolution de problèmes en classe et de l'argumentation orale.

Dans l'enseignement supérieur, l'Université de Franche-Comté (uFC) s'inscrit dans cette même trajectoire de responsabilisation en publiant une "Charte Intelligence Artificielle" qui opérationnalise le concept d'externalisation vertueuse. Loin de bannir les IAG, l'uFC reconnaît leur pertinence pour soutenir le développement de compétences transversales (idéation, structuration, communication). La charte autorise l'usage de l'IA comme outil d'assistance à la réflexion, mais interdit formellement la soumission de contenus générés "tels quels". Le point d'orgue de cette charte réside dans le transfert total de la responsabilité épistémique vers l'étudiant : ce dernier est déclaré personnellement et intégralement responsable de l'exactitude des faits avancés, de l'absence d'hallucinations algorithmiques, de l'absence de biais idéologiques et de la conformité éthique (absence de propos discriminatoires) des documents qu'il produit avec l'aide de l'IA. Pour asseoir cette responsabilité, la charte impose une exigence de transparence méthodologique radicale, exigeant des étudiants qu'ils documentent leurs méthodes d'usage de l'IA et fournissant des normes typographiques précises pour citer formellement les modèles génératifs et les requêtes utilisées dans leurs travaux académiques.

Formation Massive, Acculturation Citoyenne et Déqualification : Le Projet CAIRE

Afin de contrer structurellement le risque d'atrophie cognitive, de fracture numérique et d'asymétrie de compétences professionnelles (*deskilling*) induit par l'automatisation de l'expertise, l'Université Bourgogne Europe (UBE) pilote le projet **CAIRE** (*Citizen-oriented Artificial Intelligence training for a Responsive Education*). Reconnu comme une priorité nationale et lauréat de l'appel à manifestation d'intérêt "Compétences et métiers d'avenir" du plan d'investissement France 2030, ce projet d'envergure monumentale bénéficie de financements massifs pour atteindre un objectif ambitieux : former 28 000 personnes (incluant citoyens, étudiants et professionnels) sur une période de cinq ans.

Le projet CAIRE déploie une ingénierie de formation hybride et modulaire, s'appuyant sur un consortium d'établissements d'enseignement supérieur (dont le Cnam, Arts et Métiers, le CESI et Paris School of Business). La philosophie pédagogique de CAIRE n'est pas de former une élite d'ingénieurs en développement d'algorithmes d'apprentissage profond, mais de procéder à une "démystification" systématique de la technologie auprès du grand public et des travailleurs de divers secteurs (éducation, industrie, santé). Il s'agit de promouvoir une "éducation réactive" (Responsive Education) qui lève les craintes irrationnelles tout en armant les individus contre les manipulations algorithmiques, afin de faire de l'IA un levier d'émancipation et d'employabilité plutôt qu'un vecteur de déclassement. Le parcours de formation est structuré en niveaux de progression cognitive : de la sensibilisation aux usages responsables (Niveau 1), à l'interaction critique et l'évaluation des biais (Niveau 2), jusqu'à la maîtrise et l'intégration éthique dans les processus métiers (Niveau 3).

Au cœur de cette dynamique, le Pôle Interdisciplinaire Intelligence Artificielle (IA) de l'Université Bourgogne Europe coordonne la recherche et l'acculturation à l'échelle de l'établissement. L'Axe 3 de ce pôle de recherche se consacre spécifiquement à la complexité des enjeux sociétaux et éducatifs de l'IA. Il explore de manière dialectique l'IA en tant que formidable outil d'innovation pédagogique, mais s'attaque également frontalement, par des travaux de recherche en sciences humaines et sociales, aux risques de "déqualification" des métiers de la connaissance, à l'impact sur la productivité, aux risques d'aliénation cognitive au travail et aux nécessités d'un encadrement réglementaire éthique. Cette démarche intégrée démontre que la littératie en IA est désormais pensée non plus comme une simple compétence technique d'usage (savoir prompter), mais comme une compétence civique et épistémologique fondamentale.

L'IA au Service du Formateur et de la Recherche Action : Le Projet MOTIV'IA et le GTnum #DescolIA

L'innovation pédagogique en région académique BFC ne se limite pas à former les apprenants à utiliser l'IA ; elle explore également comment l'IA peut augmenter structurellement l'agentivité de l'éducateur et l'efficience des systèmes d'apprentissage. Le projet de recherche-action **MOTIV'IA**, initié par la DRANE en collaboration avec les Territoires Numériques Éducatifs (TNE) du Doubs et du Cher, constitue une expérimentation paradigmatique de cette approche.

Ce projet bouleverse l'approche commune de l'IA générative en inversant la dynamique d'assistance : l'outil n'est pas fourni à l'élève pour contourner l'effort de rédaction, mais il est mis à la disposition de l'enseignant pour améliorer l'impact de l'évaluation. Le projet consiste à expérimenter en situation réelle de classe, sur une durée d'un an, une solution technologique innovante (l'application *Logbook*)

qui permet à l'enseignant de formuler des retours d'évaluation (feedback) aux élèves par le biais d'un canal oral assisté et structuré par l'intelligence artificielle.

Cette démarche s'attaque à l'un des goulets d'étranglement les plus persistants de l'ingénierie pédagogique classique : le temps considérable requis pour fournir à chaque élève un feedback formatif, détaillé, différencié et suffisamment fréquent pour guider efficacement son apprentissage. En utilisant les capacités de synthèse et d'analyse structurelle de l'IA pour traiter les données d'évaluation, tout en préservant le vecteur de la voix humaine de l'enseignant (l'oralité), le projet MOTIV'IA tente de restaurer la composante relationnelle et socio-émotionnelle de l'évaluation. L'objectif est d'alléger la charge administrative du formateur tout en augmentant la motivation de l'élève par un retour perçu comme plus direct et bienveillant. Cette expérimentation est étroitement adossée à la recherche universitaire, puisqu'elle fait l'objet d'une mesure d'impact scientifique rigoureuse menée par l'Institut de recherche sur l'éducation (IREDU) de l'Université de Bourgogne. Ce projet illustre une application extrêmement précise et ciblée du domaine "AI-Pedagogical Knowledge" (AI-PK), où la technologie est circonscrite à l'amélioration du geste évaluatif de l'expert.

Dans le même esprit de recherche appliquée à la systémique scolaire, la DRANE BFC s'investit dans les Groupes de Travail Numériques nationaux, notamment le **GTnum #DescolIA (2025-2028)**. Ce programme de recherche ambitionne d'exploiter les capacités d'apprentissage automatique (Machine Learning) de l'IA pour traiter les vastes ensembles de données de terrain générés par les environnements scolaires (notes, absences, comportements, traces d'apprentissage sur les ENT). L'objectif est de concevoir des modèles d'intelligence artificielle qui soient à la fois "équitables" (dépourvus de biais discriminatoires) et "explicables" (dont la chaîne de causalité peut être comprise par un humain), afin de développer des "outils pilotes" d'analyse prédictive. Ces outils seront mis à la disposition des inspecteurs, des chefs d'établissement et des équipes pédagogiques pour identifier les signaux faibles, anticiper les décrochages scolaires potentiels et déclencher des stratégies d'intervention préventives personnalisées bien avant que la situation de l'élève ne devienne irréversible.

Ces initiatives territoriales, de la formation citoyenne à l'évaluation assistée en passant par la prédiction systémique, démontrent la formidable versatilité des applications de l'IA en éducation. Elles soulignent que le potentiel de la technologie ne se réalise pleinement que lorsqu'elle est méthodiquement scénarisée par l'ingénierie pédagogique, encadrée par une éthique forte, et systématiquement subordonnée à l'expertise décisionnelle humaine.

Stratégies et Clés pour un Regard Critique au Quotidien

La formation au discernement et la mise en œuvre de l'externalisation vertueuse nécessitent le déploiement d'un référentiel de stratégies didactiques spécifiques et actionnables au quotidien par les formateurs. Il s'agit de traduire les principes théoriques en actes pédagogiques concrets qui forcent l'apprenant à interroger la production algorithmique.

1. La Scénarisation du Doute et le Reverse-Engineering

L'ingénierie pédagogique doit concevoir des tâches qui déplacent le statut de l'IA générative : d'un outil de production invisible et final, elle doit devenir un objet matériel d'analyse, d'investigation et de critique explicite.

- **Le Reverse-Engineering (Ingénierie Inverse) d'Outputs Générés :** Au lieu de demander aux étudiants de rédiger un essai de zéro, le formateur fournit une thématique complexe et impose aux étudiants de générer le texte via un LLM (comme GPT-4 ou Claude) en utilisant des prompts de base. Le cœur de l'exercice didactique commence alors : les étudiants doivent engager un processus d'ingénierie inverse sur ce texte algorithmique. Ils sont évalués sur leur capacité à "déconstruire" la réponse générée. Cela implique de repérer les sauts logiques, de vérifier la factualité de chaque affirmation par des recherches documentaires externes croisées, d'identifier les stéréotypes cachés sous la neutralité apparente du ton, et surtout, de mettre en lumière ce que l'IA a volontairement omis de traiter — ses angles morts cognitifs souvent liés aux biais de surreprésentation culturelle anglo-centrée de ses corpus d'entraînement. L'apprenant redevient ainsi le maître d'œuvre de la validation du savoir.
- **Le Prompting Critique et Itératif :** Il est fondamental de former les étudiants à l'art complexe de l'ingénierie de requêtes (prompt engineering), non pas dans une perspective de productivité pure pour obtenir "la réponse magique" du premier coup, mais dans une perspective critique. L'ingénierie pédagogique demande aux étudiants de concevoir des "prompts" exigeants qui forcent l'algorithme à révéler ses limites ou à adopter des postures de pensée divergentes. Par exemple : « *Rédige une synthèse sur les causes de la Première Guerre mondiale, mais intègre trois paragraphes expliquant cet événement selon des courants historiographiques totalement opposés, et souligne explicitement les limites épistémologiques de chacune de ces approches.* » L'évaluation de l'étudiant portera dès lors sur la qualité intellectuelle, la précision et la créativité des contraintes qu'il a su formuler dans ses invites (prompts), et non sur le texte final rédigé par la machine.
- **L'Exercice de la Contradiction Socratique :** Transformer l'IA en un contradicteur automatique. L'étudiant formule sa thèse personnelle, puis est sommé d'utiliser l'IA générative exclusivement pour qu'elle produise les meilleurs contre-arguments et contre-exemples possibles visant à détruire sa thèse initiale. L'étudiant doit ensuite rédiger une défense structurée pour répondre aux attaques générées par la machine, utilisant ainsi la puissance computationnelle de l'outil pour éprouver et solidifier la robustesse de son propre jugement humain.

2. Externalisation du Raisonnement et Traçabilité Métacognitive

Pour lutter efficacement contre l'opacité et l'effet "boîte noire" du travail intellectuel assisté par l'IA, l'ingénierie pédagogique doit exiger la matérialisation et l'externalisation continues des processus cognitifs de l'étudiant. La genèse de la pensée doit redevenir observable.

- **Le Journal de Bord de l'IA (AI-Log) et les Portfolios Métacognitifs :** Lors de la réalisation de travaux longs (mémoires, dossiers de recherche, projets de conception), l'étudiant doit tenir un portfolio métacognitif ou un journal de bord obligatoires. Dans ce document annexe, il est tenu de documenter précisément la chronologie de son interaction avec les systèmes d'IA générative : Quelles hypothèses de départ ont motivé le recours à l'IA? Quelles requêtes exactes ont été formulées? Quelles propositions algorithmiques ont été formellement rejetées et pour quelles raisons critiques? Comment les informations extraites de l'IA ont-elles été triangulées et validées avec des sources académiques ou scientifiques de référence primaire? Cet exercice force un retour réflexif permanent sur ses propres actions, rendant le processus d'externalisation conscient et délibéré.

- **La Cartographie Conceptuelle Préalable :** Avant d'être autorisé à utiliser un LLM pour structurer ses idées ou rédiger un brouillon, l'apprenant doit concevoir manuellement une "carte conceptuelle" (mind map) détaillée de son raisonnement et des liens de causalité qu'il compte explorer. Cette architecture cognitive personnelle sert ensuite de grille d'évaluation de référence : l'étudiant s'en servira pour mesurer dans quelle proportion la structure ultérieurement générée par l'algorithme respecte, enrichit ou dévie de sa compréhension conceptuelle initiale.

3. Diversification et Sécurisation des Modalités d'Évaluation

La prolifération des IA génératives sonne définitivement le glas de l'hégémonie de l'évaluation classique basée sur la remise d'un "devoir maison" textuel et asynchrone non supervisé. L'ingénierie pédagogique est contrainte de réinventer ses modalités d'évaluation pour garantir que l'apprentissage a bien transformé l'architecture cognitive interne de l'élève, et non simplement transité par les serveurs d'un modèle d'apprentissage profond.

- **Les Évaluations "Open IA" Axées sur la Justification :** Le paradigme bascule de l'interdiction à l'intégration mesurée. Dans ces modèles d'évaluation en classe ou à distance, l'utilisation de l'IA générative est explicitement autorisée. Cependant, la grille de notation (rubrique d'évaluation) se désintéresse presque totalement de la qualité syntaxique du livrable final. Les critères d'excellence portent exclusivement sur la capacité démontrée de l'étudiant à justifier ses choix épistémologiques, à annoter de manière critique les limites du résultat produit par l'algorithme, à distinguer précisément ce qui relève de l'apport mécanique de la machine de sa propre "valeur ajoutée" intellectuelle, et à démontrer la méthodologie de vérification factuelle qu'il a mise en œuvre.

- **Le Renforcement Drastique de la Communication Synchrone et Située :** Pour évaluer de manière incontestable la compréhension profonde et l'intégration mémorielle, les dispositifs de formation réinvestissent massivement dans les évaluations en temps réel, non médiées par les écrans. Les soutenances orales prolongées (où l'étudiant doit répondre à des questions inattendues testant sa capacité de transfert de connaissances), les débats argumentatifs en classe, les interrogations spontanées et la résolution de cas pratiques complexes et collaboratifs (réalisés en environnement contrôlé sans connexion réseau) redeviennent les mètres étalons incontournables de la certification académique. Ces modalités échappent structurellement aux biais de l'offloading textuel algorithmique et remettent la difficulté désirable de la "récupération active" au centre du processus évaluatif.

Épilogue : L'Horizon Émancipateur

Former au discernement et à l'esprit critique à l'ère prolifique des intelligences artificielles génératives ne consiste absolument pas à rajouter un vernis technologique superficiel sur des structures et des dogmes pédagogiques obsolètes. L'irruption globale des LLM, avec leur stupéfiante capacité à générer une fluidité syntaxique mimétique et à induire, chez l'humain, un profond et séduisant confort cognitif, exige rien de moins qu'une refondation épistémologique des sciences de l'apprentissage.

Si la délégation massive des tâches cognitives (le *cognitive offloading*) aux algorithmes probabilistes permet incontestablement d'accélérer la performance superficielle et d'augmenter la productivité formelle immédiate, elle recèle, en son cœur, le danger systémique d'atrophier l'esprit critique humain. Sans cadre ingénierique, cette délégation biaise le jugement, dissout la capacité d'analyse

indépendante et efface les "difficultés désirables" — ces frictions intellectuelles indispensables à la plasticité neuronale, à l'ancrage mémoriel à long terme et à la construction d'une pensée authentiquement singulière.

L'ingénierie pédagogique moderne, éclairée par des modèles d'intégration sophistiqués tels que l'AI-TPACK et incarnée par des initiatives d'acculturation massives et territoriales (à l'image du projet CAIRE, du projet MOTIV'IA ou du cadre d'usage précurseur de la région académique Bourgogne-Franche-Comté), doit opérer un changement de paradigme décisif. Il s'agit d'accompagner la transition d'une logique historique de transmission et de restitution de savoirs vers une pédagogie exigeante de la vérification, de l'orchestration de l'information et du doute méthodique.

En reconfigurant radicalement le rôle du formateur — qui délaisse la posture de détenteur unique du savoir pour devenir l'architecte subtil de l'"espace dialogique" —, et en transformant les IA génératives de leur statut d'oracles de substitution en de véritables partenaires critiques et altérités génératives, les systèmes d'éducation pourront véritablement promouvoir une dynamique d'externalisation vertueuse. Le défi n'est plus de lutter contre l'intelligence artificielle, mais de s'en servir comme d'un révélateur et d'un propulseur des capacités humaines. L'apprenant du XXIe siècle ne sera alors plus un simple consommateur docile de réponses probabilistes fluides, mais un sujet pensant, éthique et souverain, capable d'instrumentaliser la colossale puissance algorithmique pour augmenter, en pleine conscience, son humanité, sa créativité et sa rigueur intellectuelle face à la complexité du monde.

Glossaire

- **Aisance Cognitive (Cognitive Ease) :** Biais psychologique majeur décrit par Daniel Kahneman, par lequel le cerveau assimile un contenu présenté de manière fluide, esthétique, claire et familière (comme les textes lisses générés par les LLM) à un contenu véridique et fiable. Ce sentiment de confort désactive la vigilance et le traitement analytique critique (le Système 2).
- **Cortex Cingulaire Antérieur (ACC) :** Région nodale du cerveau impliquée dans la détection des erreurs, des anomalies, des incohérences et des conflits. Son activité neurobiologique, moteur de la remise en question, est souvent dangereusement amoindrie lors de la lecture des productions lisses et hautement plausibles de l'IA générative.
- **Difficultés Désirables (Desirable Difficulties) :** Concept fondamental en sciences de l'apprentissage (Robert Bjork) désignant des conditions et des stratégies pédagogiques qui introduisent volontairement des frictions ou des obstacles à court terme (espacement des révisions, entrelacement des sujets, récupération mémorielle active). Ces difficultés ralentissent la performance immédiate mais améliorent significativement et durablement la rétention et le transfert des connaissances à long terme.
- **Espace Dialogique (Dialogic Space) :** Concept théorique éducatif (Rupert Wegerif) décrivant l'environnement intellectuel d'échange, de confrontation et de co-construction de sens, au sein duquel une IA générative, de par sa capacité à proposer des alternatives inattendues, peut agir comme un "partenaire dialogique" (dialogic partner) non-humain pour catalyser la réflexion critique.

- **Externalisation Cognitive (Cognitive Offloading) :** Fait, pour un être humain, de s'appuyer sur l'environnement physique ou sur des artefacts technologiques avancés (carnets, calculatrices, GPS, moteurs de recherche, IA génératives) pour réduire la demande, l'effort et la charge incombant aux processus cognitifs internes du cerveau.
- **Externalisation Vertueuse (Virtuous Outsourcing) :** Délégation responsable, critique et lucide d'une tâche cognitive à une IA (Gopal et Quinn), motivée par une intention pédagogique claire. Elle vise à réallouer son effort mental interne vers des tâches d'ordre intellectuel, éthique ou créatif supérieur, plutôt que de procéder à un simple évitement de l'effort par paresse cognitive.
- **Hallucination (IA) :** Dans le contexte des modèles de langage probabilistes, phénomène de génération de productions factuellement incorrectes, illogiques, biaisées ou inventées de toutes pièces, qui sont formulées par la machine avec une syntaxe logique parfaite et un ton d'assurance mimant l'expertise humaine, trompant ainsi la vigilance de l'utilisateur.
- **Modèle AI-TPACK :** Extension du cadre théorique TPACK (Technological Pedagogical Content Knowledge). Il définit l'ensemble des compétences complexes requises par les formateurs à l'ère de l'IA, exigeant l'intégration harmonieuse entre la maîtrise technique des outils d'IA (AI-TK), la compréhension de leur impact sur les contenus disciplinaires (AI-CK), et l'expertise didactique pour scénariser leur usage de manière éthique et pédagogiquement pertinente (AI-PK).
- **Prompting Critique (Ingénierie de Requête Réflexive) :** Méthodologie d'ingénierie de requêtes (prompts) visant non pas à obtenir une solution simple, finale ou lissée de l'IA, mais à contraindre la machine à révéler ses biais, à sourcer ses affirmations, ou à générer des arguments contradictoires afin de stimuler l'analyse délibérative et dialectique de l'utilisateur humain.
- **Système 1 et Système 2 :** Modèle conceptuel de psychologie comportementale (Daniel Kahneman) décrivant l'architecture de la pensée humaine. Le Système 1 est archaïque, rapide, intuitif, heuristique et très économique en énergie métabolique ; le Système 2 est évolutif, lent, délibéré, logique, analytique et requiert un effort de concentration intense. L'IA générative sollicite massivement la confiance du Système 1 tout en maintenant le Système 2 en sommeil.

Sources

Singh, A., Taneja, K., Guan, Z., & Ghosh, A. (2025). Protecting Human Cognition in the Age of AI. arXiv preprint arXiv:2502.12447v3.

Lee et al. (2025). The Impact of Generative AI on Critical Thinking. Microsoft Research.

Gerlich. (2025). The relationship between AI tool usage and critical thinking skills, focusing on cognitive offloading as a mediating factor. MDPI.

PMC. (2025). Cognitive Consequences of Having Information at Our Fingertips / The Extended Mind / Cognitive Offloading.

Guo et al. (2024). LLMs and Linguistic Variation / Kleinberg (2021). Algorithmic convergence in complex systems. arXiv preprint arXiv:2508.01491v2.

Microsoft Research Video. (2025). The Illusion of Inclusion: How LLMs misrepresent cultural contexts.

Preprints. (2025). LLMs, as currently designed, demonstrate an illusion of intelligence.

Royal Society Publishing. (2025). Generalization bias in large language models.

Perez, C. E. (2025). Thinking Machines, Not Acting Beings: The Illusion of Agency in Large Language Models. Medium / Intuition Machine.

The Decision Lab. System 1 and System 2 Thinking (Daniel Kahneman).

Kahneman, D. (2011). Thinking, Fast and Slow. Summary of Concepts.

Structural Learning. (2025). Robert Bjork: Teachers Guide to Desirable Difficulties.

Bjork, E. L., & Bjork, R. A. (2011). Making Things Hard on Yourself, But in a Good Way: Creating Desirable Difficulties to Enhance Learning. Psychology and the Real World.

Psychological Science. (2025). Desirable Difficulties vs man-made storage/memory devices.

Living Lab Cnam. (2025). Projet CAIRE, pour former les citoyens à une intelligence artificielle responsable.

ResearchGate. (2025). Uniting the Tribes of Fluency to Form a Metacognitive Nation / Cognitive ease.

Begg, I., Anas, A. P., & Farinacci, S. (1992). Illusion of Truth. Journal of Experimental Psychology: General.

Stegemann, M. (2024). Autobahn statt Trampelpfad: Mit „Fluency“ zum Ziel: Fluency, Cognitive Ease.

Bjork, R. A., & Bjork, E. L. (2020). Desirable difficulties in theory and practice. Journal of Applied Research in Memory and Cognition.

ResearchGate. (2025). Cognitive ease shapes engineering judgement, influences diagnostic reasoning, and contributes to oversimplified narratives.

Social Market Foundation. (2025). EducAItion: Defining the Science of Learning / Bjork & Bjork, Desirable Difficulties.

Académie de Dijon / Région Académique Bourgogne-Franche-Comté. (2025). Cadre d'usage de l'IA en éducation.

DRANE Bourgogne-Franche-Comté. (2025). Cadre d'usage de l'IA en éducation (Règles, éthique et progressivité).

Long, E. (2026). From Reflection to Action: The Role of Retrieval Practice in Deepening Learning and Instruction.

Bellwether. (2025). Productive struggle (Desirable difficulties, zone of proximal development).

Zeng, S. A. (2025). Dialogues in Play: Conversational AI and Early Mathematical Thinking / Rupert Wegerif, dialogic education.

Wegerif, R. (2010). The role of dialog in teaching thinking in technology.

World Bank Blogs. (2025). Is AI making us smarter or just making us look smart? / Performance vs Learning.

PMC. (2025). Extraneous cognitive load vs desirable difficulties in human-chatbot interactions.

Applied Clinical Trials. (2025). Rethinking training: The benefits of embracing desirable difficulties over passive didactic experiences.

Taylor & Francis. (2026). Intelligent-TPACK (I-TPACK) framework: Interdisciplinary AI literacy and competency.

MDPI. (2025). AI-TPACK Assessment Framework: Integrating AI into technological, pedagogical, and content knowledge.

Ning et al. (2024). AI-TPACK framework and AI-Pedagogical Knowledge (AI-PK).

Gopal, W., & Quinn, M. (2025). Engaging with Film to Teach Students About Virtuous Outsourcing of Cognitive Tasks to LLMs. Digital Society.

Cassinadri. (2024). Cognitive extension and cognitive offloading to ChatGPT in educational contexts.

OUP / Journal of Philosophy of Education. (2025). The Extended Mind and Virtuous Outsourcing of Cognitive Tasks.

PMC. (2025). Generative AI and cognitive offloading: Neurobiological risk of maximum cognitive ease bypassing conflict recognition by the ACC.

Stadler, M., Bannert, M., & Sailer, M. (2024). Cognitive ease at a cost: LLMs reduce mental effort but compromise depth in student scientific inquiry. Computers in Human Behavior.

UNESCO. (2025). AI and Education for Collective Intelligence / Rupert Wegerif.

Wegerif, R., & Casebourne, I. (2025). A dialogic theoretical foundation for integrating generative AI into pedagogical design. British Journal of Educational Technology.

Gopal, W., & Quinn, M. (2025). Learning Andy Clark & David Chalmers' 'The Extended Mind' through Christopher Nolan's Memento. Journal of Philosophy of Education.

PMC. (2025). Large Language Models and the 'Expertise Duality' / Cognitive ease vs deep learning.

MedRxiv. (2025). Cognitive ease of narrative persuasion / LLM cohesive and apparently complete diagnostic story creating an illusion of understanding.

arXiv. (2025). AI–derivative epistemology, epistemic deference, and cognitive ease / Illusions of Understanding in Scientific Research.

Science Publishing Group. (2025). The goal of AI in education must be to build better thinkers, not better prompters / Desirable difficulties.

PNAS Nexus. (2025). Cognitive ease at a cost: LLMs reduce mental effort but compromise depth in student scientific inquiry.

Université Bourgogne Europe (UBE). Pôle Interdisciplinaire IA / Éthique & soutenabilité, encadrement réglementaire, IA éthique.

Frontiers in Education. (2025). TPACK framework with GenAI for professional development / Harmonizing technology with pedagogy and content.

Taylor & Francis. (2026). AI-Content Knowledge (I-CK) and AI-Pedagogical Knowledge (I-PK) bridging technical and practical skills via critical literacies.

Journal of Software Engineering and Applications. (2025). Bridging the Gap: The AI-TPACK Model for Teacher Professional Development.

Gopal, W. (2025). Engaging with Film to Teach Students About Virtuous Outsourcing of Cognitive Tasks to LLMs.

ResearchGate. (2025). Generative AI as a dialogic partner that enriches the collective pursuit of meaning vs Authority/Master.

Wegerif, R. (2011, 2025). Dialogic pedagogy and engagement with the irreducibly other / Generative alterity of GenAI.

Zeng, S. A. (2025). Dialogic pedagogy, cognitive scaffolding, and conversational AI as a potential mediator.

Bjork, R. A., & Bjork, E. L. (2020). Desirable difficulties in theory and practice: Retrieval practice in deep learning.

Wegerif, R. (2024). Dialogic space to maximise the complementary capabilities of humans and AI.

Biesta (2019) / Wegerif (2025). Dialogic education with technology / Reflection and productive tension.

Techniques de l'Ingénieur. (2025). Impact de l'IA générative sur la pensée critique : dépendance à long terme et confiance en soi.

Lee et al. (2025). Higher confidence in GenAI is associated with less critical thinking / Overconfidence in AI capabilities.

Arts et Métiers. (2026). Le projet CAIRE : vers une formation responsable à l'IA (Niveaux de sensibilisation, appropriation et intégration).

Académie de Dijon. (2025). Cadre d'usage de l'intelligence artificielle en éducation (Principes éthiques, protection des données, modalités d'évaluation).

ICB CNRS. (2025). Projet CAIRE : Former 28 000 personnes à l'intelligence artificielle en cinq ans pour une éducation responsable.

Université de Franche-Comté (uFC). Charte Intelligence Artificielle pour les étudiants et les enseignants.

UBE. Pôle Interdisciplinaire IA de l'Université Bourgogne Europe / Stratégie et acculturation IA.

DRANE BFC. (2025). INFONUM - Projet MOTIV'IA : Expérimenter un retour oral assisté par IA pour l'évaluation des élèves (Logbook).

ICB CNRS. Projet CAIRE et l'approche pédagogique inclusive et de démystification de l'IA.

UBE. L'IA comme outil d'innovation pédagogique et risque de déqualification des compétences.

ICB CNRS. Pédagogie de l'IA responsable et démystification technologique (Responsive Education).

UBE. Étude de l'impact de l'IA sur le travail, les organisations et le risque d'aliénation au sein de l'Axe 3.

DRANE BFC. (2026). Règles d'utilisation concrètes de l'IA pour les élèves et fraude académique.

DRANE BFC. GTnum #DescolIA : Modélisation et Intelligence Artificielle au service de la prédiction du décrochage scolaire.

uFC. Méthodologie et citation de l'IA dans les travaux académiques / Responsabilité et exactitude des contenus.

DRANE BFC. TraAM (Travaux académiques mutualisés) et production de scénarios pédagogiques liés à l'IA indexés dans Édubase.